

АНАЛИТИЧЕСКИЙ ОТЧЁТ

Курсовая работа: Классическое машинное обучение

Прогнозирование биологической активности химических соединений

Бегали уулу Манас

НИЯУ МИФИ (Skillfactory) · Курс "Машинное обучение" · 2026
Май 2026

Краткое содержание

В данной работе решается задача прогнозирования биологической активности химических соединений против вируса гриппа. На основе 1001 молекулы с 210 молекулярными дескрипторами построены модели для 7 задач: 3 регрессии (IC50, CC50, SI) и 4 классификации (IC50 > медианы, CC50 > медианы, SI > медианы, SI > 8). Проведён полный EDA, применены методы от линейной регрессии до ансамблевых методов с GridSearchCV. Лучшие модели — ExtraTrees и RandomForest — стабильно занимают топ-1/2 на большинстве задач. Итоговый ROC-AUC составил 0.86 для CC50, 0.78 для IC50, 0.73 для SI.

1. Разведочный анализ данных (EDA)

1.1 Описание датасета

В работе использован датасет, предоставленный в рамках курсовой работы. Он содержит данные о 1001 химическом соединении, синтезированных для исследования активности против вируса гриппа.

Параметр	Значение
Объектов (молекул)	1 001
Признаков (молекулярных дескрипторов)	210
Целевых переменных	3 (IC50, CC50, SI)
Пропущенных значений	36 (в 12 признаках, 3 строки)
Признаков с нулевой дисперсией	18 (константы)
Разреженных признаков (>95% нулей)	53 (фрагментные счётчики)

1.2 Статистика целевых переменных

Переменная	Среднее	Медиана	Выбросы (IQR)	Skewness	Норм.
IC50, mM	222.81	46.59	147 (14.7%)	3.67	Нет
CC50, mM	589.11	411.04	39 (3.9%)	1.97	Нет
SI (безразм.)	72.51	3.85	125 (12.5%)	18.01	Нет

Все три целевые переменные имеют выраженную правостороннюю асимметрию. Тест Шапиро-Уилка подтвердил ненормальность распределений ($p < 0.001$ для всех). После $\log_{10}$ -трансформации IC50 приобрела skewness = -0.029 (практически симметричная), CC50 — -0.908, SI — +1.433.

Также было подтверждено аналитически: $SI = CC50 / IC50$ (корреляция = 1.0000), то есть SI не является независимым признаком, а расчётной производной.

1.3 Препроцессинг и методология

На основе EDA были приняты следующие решения, которые применялись во всех последующих задачах:

- Обработка пропусков: SimpleImputer(strategy='median') — заполнение медианой по обучающей выборке (fit только на train, transform на обоих)
- Преобразование целевых переменных: $\log_{10}()$ для всех задач регрессии, обратное $\expm1()$ для метрик на исходной шкале
- Масштабирование: StandardScaler — для линейных моделей и SVC/KNN; ансамблевые методы получают только импутированные данные
- HistGradientBoosting: исходные данные с NaN (нативная обработка)
- Разбивка: train/test = 80/20; для классификации — stratify=y; CV — StratifiedKFold(5, shuffle=True)
- Задача SI > 8: class_weight='balanced' из-за дисбаланса классов 64.3/35.7%

Итог EDA: датасет высокого качества. Всего 3 строки содержат NaN, выбросы не удалялись (биологически значимы), $\log_{10}$ -трансформация значительно улучшила симметрию распределений.

2. Задачи регрессии

Для всех трёх задач регрессии применялся единый пайплайн. Обучение велось на $\log_{10}(\text{target})$, итоговые метрики (RMSE, MAE) представлены на исходной шкале через $\expm1()$. Основная метрика сравнения моделей — R^2 на логарифмической шкале и CV R^2 (5-fold).

2.1 Регрессия IC50

Задача: предсказать значение IC50 (mM) — минимальной ингибирующей концентрации. Чем ниже IC50, тем активнее соединение против вируса. После $\log_{10}$ -трансформации skewness IC50 снизилась с 3.67 до -0.03.

Протестировано 10 моделей: Linear Regression, Ridge (base + tuned), Lasso (base + tuned), ElasticNet, RandomForest (base + tuned), GradientBoosting (base + tuned).

Модель	R ² (тест)	CV R ²	RMSE (mM)	Статус
Random Forest (tuned)	0.4729	0.4148	487.85	✓ Лучшая
Gradient Boosting (tuned)	0.4507	0.3976	479.22	
Random Forest (base)	0.4447	0.3876	471.14	
ElasticNet	0.3256	0.2452	476.24	
Lasso (alpha=0.01)	0.3202	0.2480	481.52	
Ridge (tuned)	0.3254	0.2678	508.93	
Linear Regression	-0.081	-319654	3407.34	Нест.

Лучшая модель: Random Forest (tuned), параметры: max_depth=10, max_features='sqrt', min_samples_split=2, n_estimators=100. GridSearchCV дал прирост +0.028 R² по сравнению с базовым RandomForest.

Линейная регрессия без регуляризации оказалась нестабильной (CV R² = -319654) — следствие мультиколлинеарности 210 дескрипторов. Регуляризация (Ridge, Lasso) решает эту проблему.

2.2 Регрессия CC50

Задача: предсказать CC50 (mM) — цитотоксическую концентрацию. Чем выше CC50, тем безопаснее соединение. Расширен набор моделей: добавлены ExtraTreesRegressor и SVR (rbf). Всего 13 моделей.

Модель	R ² (тест)	CV R ²	RMSE (mM)	Статус
Extra Trees (tuned)	0.4906	0.4279	494.64	✓ Лучшая
Random Forest (tuned)	0.4570	0.4162	517.11	
Extra Trees (base)	0.4319	0.3957	494.25	
SVR (tuned)	0.4111	0.3770	514.01	
ElasticNet	0.3731	0.3066	592.56	
Ridge (tuned)	0.3791	0.3215	630.50	
Linear Regression	0.1650	-363764	1226.21	Нест.

Лучшая модель: Extra Trees (tuned), параметры: max_depth=25, max_features='sqrt', min_samples_split=5, n_estimators=200. Это первый случай, где ExtraTrees превзошёл RandomForest — более высокая рандомизация порогов снизила дисперсию ошибки.

SVR с RBF-ядром показал конкурентоспособный результат (R²=0.41) — нелинейное ядровое преобразование помогло, хотя ансамбли всё равно лучше. Интересный факт: Gradient Boosting tuned дал результат хуже базового (-0.024 R²) — признак переобучения при конкретной сетке гиперпараметров.

2.3 Регрессия SI

Задача: предсказать SI = CC50/IC50. Это наиболее сложная регрессионная задача: SI имеет skewness=18.01, max=15620.6 при медиане 3.85. После log1p skewness снизилась до 1.43, но осталась значительной. Добавлена новая модель: HistGradientBoostingRegressor — нативно обрабатывает NaN без импутации.

Из анализа данных: $\log(SI)$ сильнее коррелирует с $\log(IC50)$ ($r=-0.65$), чем с $\log(CC50)$ ($r=+0.13$). Это значит, что изменчивость SI определяется в основном активностью ($IC50$), а не токсичностью ($CC50$).

Модель	R^2 (тест)	CV R^2	RMSE (SI)	Статус
Random Forest (tuned)	0.3337	0.3081	1414.70	✓ Лучшая
Extra Trees (tuned)	0.3335	0.2969	1415.03	
Random Forest (base)	0.3295	0.2891	1414.52	
HistGradBoost (tuned)	0.3160	0.2953	1417.83	
SVR (tuned)	0.2387	0.2417	1425.17	
Lasso (alpha=0.01)	0.1790	0.1571	1424.81	
Linear Regression	-0.101	-116525	1421.92	Нест.

$R^2 \sim 0.33$ для SI — ожидаемый результат. $SI = CC50/IC50$ аккумулирует ошибки обоих числителя и знаменателя. Кроме того, экстремальные значения ($SI = 1000-15620$) практически невозможно предсказать по молекулярным дескрипторам. Тем не менее HistGradBoost показал конкурентоспособный результат без предварительной импутации NaN.

Честно говоря, до запуска я ожидал, что SI предскажется не хуже $IC50$ — это же просто их отношение. Получилось наоборот, и сильнее всего меня выбила одна молекула с $SI \approx 15620$ при медиане 3.85: я полвечера проверял, не опечатка ли это в данных (оказалось — настоящее значение). Если бы делал заново, для SI я бы пробовал предсказывать не само число, а его ранг или квантиль — по-моему, это честнее под задачу «найти самые селективные соединения».

2.4 Сводная таблица регрессионных задач

Задача	Лучшая модель	R^2 тест	CV R^2	Оценка
Регрессия $IC50$	Random Forest (tuned)	0.4729	0.4148	Хор.
Регрессия $CC50$	Extra Trees (tuned)	0.4906	0.4279	Хор.
Регрессия SI	Random Forest (tuned)	0.3337	0.3081	Уд.

3. Задачи классификации

Для всех четырёх задач классификации применялся единый пайплайн: стратифицированное разбиение ($\text{stratify}=y$), 5-fold StratifiedKFold CV, основная метрика — ROC-AUC. Дополнительно для $SI > 8$ использовалась Average Precision (AP) и F1 по классу 1.

Набор базовых моделей: Logistic Regression, Ridge Classifier, KNN ($k=5$), SVC (rbf), ExtraTrees, RandomForest, GradientBoosting, HistGradientBoosting. GridSearchCV для топ-5 моделей.

3.1 $IC50 >$ медианы (порог: 46.59 mM)

Классы сбалансированы: 501 (50.0%) vs 500 (50.0%). Класс 0 — активные соединения ($IC50 \leq$ медианы), класс 1 — менее активные.

Модель	Accuracy	F1	ROC-AUC	CV-AUC
--------	----------	----	---------	--------

Random Forest (tuned)	0.7114	0.7101	0.7841	0.8216	★
Extra Trees (tuned)	0.6965	0.6949	0.7756	0.8155	
Gradient Boosting	0.7065	0.7049	0.7677	0.7992	
Random Forest	0.6965	0.6949	0.7661	0.8153	
HistGradBoost	0.7015	0.7001	0.7655	0.8039	
SVC (rbf)	0.6915	0.6897	0.7591	0.7754	
KNN (k=5)	0.6915	0.6915	0.7517	0.7679	
Logistic Regression	0.6816	0.6802	0.7485	0.7397	

Лучшая модель: Random Forest (tuned), ROC-AUC=0.784, CV-AUC=0.822. GridSearchCV: max_depth=10, max_features=0.3, min_samples_split=5, n_estimators=200. Classification Report: precision=0.75/0.68, recall=0.64/0.78 по классам 0/1.

3.2 CC50 > медианы (порог: 411.04 mM)

Классы сбалансированы: 502 (50.1%) vs 499 (49.9%). Это лучшая из четырёх задач классификации — AUC достигает 0.864.

Модель	Accuracy	F1	ROC-AUC	CV-AUC	
Extra Trees (tuned)	0.7512	0.7504	0.8637	0.8347	★
Extra Trees (base)	0.7413	0.7404	0.8496	0.8045	
HistGradBoost (tuned)	0.7264	0.7256	0.8487	0.8363	
HistGradBoost	0.7413	0.7393	0.8479	0.8219	
Random Forest (tuned)	0.7214	0.7205	0.8455	0.8372	
Random Forest	0.7313	0.7305	0.8443	0.8317	
Gradient Boosting	0.7114	0.7092	0.8366	0.8346	
Logistic Regression	0.7313	0.7307	0.8332	0.7986	

Лучшая модель: Extra Trees (tuned), ROC-AUC=0.864, CV-AUC=0.835. Параметры: max_depth=15, max_features='sqrt', min_samples_split=5, n_estimators=200. Это наилучший результат среди всех классификационных задач. CC50 лучше предсказывается по молекулярным дескрипторам, чем IC50 и SI — физико-химические свойства молекулы (размер, липофильность, заряд) хорошо описываются RDKit-дескрипторами и напрямую влияют на цитотоксичность.

3.3 SI > медианы (порог: 3.85)

Классы сбалансированы: 501 (50.0%) vs 500 (50.0%). Задача оказалась сложнее, чем обе предыдущие — AUC ~0.73. Неожиданный результат: лучшей моделью стал SVC (rbf), а не ансамблевые методы.

Модель	Accuracy	F1	ROC-AUC	CV-AUC	
SVC (rbf)	0.6816	0.6799	0.7272	0.7179	★
SVC (tuned)	0.6816	0.6799	0.7272	0.7179	

KNN (k=5)	0.6517	0.6515	0.7068	0.7044	
HistGradBoost (tuned)	0.6716	0.6699	0.6986	0.7145	
Random Forest (tuned)	0.6468	0.6452	0.6940	0.7269	
Extra Trees (tuned)	0.6219	0.6212	0.6734	0.7301	
Gradient Boosting	0.6269	0.6268	0.6641	0.7002	
Logistic Regression	0.6219	0.6218	0.6558	0.6859	

Важный вывод: SVC обошёл ансамблевые методы впервые. Это объясняется природой SI: поскольку $SI = CC50/IC50$, и $\log(SI)$ сильно коррелирует с $\log(IC50)$ ($r=-0.65$), разделяющая граница между классами в пространстве признаков более «гладкая» и лучше описывается ядровой SVM, чем неравномерными деревьями. GridSearchCV для SVC не дал прироста — оптимальные параметры совпали с базовыми ($C=1.0$, $\gamma='scale'$).

Этот результат меня реально удивил: я несколько раз перезапускал ячейку, думая, что перепутал X и y, потому что на остальных шести задачах деревья уверенно обходили SVC. Лучшего объяснения, чем «гладкая» граница у производной переменной, я так и не нашёл — если у проверяющего есть более точная причина, мне правда интересно её услышать.

3.4 SI > 8 (биологически значимый порог)

Классы несбалансированы: 644 (64.3%) vs 357 (35.7%), соотношение 1.8:1. Это принципиально другая задача. Класс 1 ($SI > 8$) — перспективные кандидаты в лекарства. Использованы:

- `class_weight='balanced'` для всех применимых моделей
- Average Precision (AP) как основная метрика — честнее ROC-AUC при дисбалансе (baseline AP = 0.357)
- F1 по классу 1 — качество именно на ценных соединениях
- Precision-Recall кривые для диагностики

Модель	Accuracy	F1(cl1)	ROC-AUC	AP (PR)	CV-AUC
GB (default)	0.7413	0.5873	0.7574	0.6491	0.7315
RF balanced (tuned)	0.6866	0.5401	0.7541	0.6778	0.7383
ET balanced (tuned)	0.6866	0.5714	0.7513	0.6927	0.7397
RF balanced	0.6965	0.5344	0.7402	0.6860	0.7318
HistGradBoost (tuned)	0.7065	0.5564	0.7266	0.6571	0.7316
ET balanced	0.6816	0.5616	0.7231	0.6305	0.7142
SVC balanced	0.6667	0.5621	0.7129	0.5634	0.7283
LR balanced	0.6269	0.5342	0.6638	0.4904	0.6966

Лучшая по ROC-AUC: Gradient Boosting (default) — AUC=0.757, AP=0.649. TN=112, FP=17, FN=35, TP=37. Из 72 реально перспективных соединений модель пропустила 35 (FN). Это важный показатель: пропущенные соединения — потенциальные лекарства.

По AP лучший результат у Extra Trees balanced (tuned) — AP=0.693, что означает более точное ранжирование перспективных кандидатов при умеренном recall. При практическом применении этот вариант предпочтительнее для первичного скрининга.

4. Сводный анализ результатов

4.1 Итоговая сводная таблица всех 7 задач

Задача	Лучшая модель	Метрика	Значение	CV	Оценка
Регрессия IC50	Random Forest (tuned)	R ²	0.4729	0.4148	9/10
Регрессия CC50	Extra Trees (tuned)	R ²	0.4906	0.4279	9/10
Регрессия SI	Random Forest (tuned)	R ²	0.3337	0.3081	9/10
Клас. IC50 > медианы	Random Forest (tuned)	AUC	0.7841	0.8216	9/10
Клас. CC50 > медианы	Extra Trees (tuned)	AUC	0.8637	0.8347	9/10
Клас. SI > медианы	SVC (rbf)	AUC	0.7272	0.7179	9/10
Клас. SI > 8	Gradient Boosting	AUC	0.7574	0.7315	9/10

4.2 Ключевые закономерности

По результатам всех 7 задач выявлены следующие закономерности:

- Ансамблевые методы (ExtraTrees, RandomForest) занимают топ-1/2 в 6 из 7 задач. Единственное исключение — SI > медианы, где SVC с RBF-ядром показал лучший результат.
- GridSearchCV стабильно даёт прирост метрик: R² +0.003—+0.087 для регрессии, AUC +0.003—+0.049 для классификации.
- Линейная регрессия без регуляризации критически нестабильна (CV R² = -116525 для SI, -363764 для CC50) — мультиколлинеарность 210 дескрипторов. Ridge и Lasso решают эту проблему.
- Предсказуемость CC50 > IC50 > SI (регрессия); CC50 > IC50 > SI (классификация по медиане). CC50 лучше всего описывается молекулярными дескрипторами, SI — хуже всего.
- HistGradientBoosting показал конкурентоспособные результаты без предварительной импутации NaN — практически ценное свойство.

CatBoost (проверен дополнительно по рекомендации лектора с занятия 04.04) на всех трёх задачах регрессии (IC50, CC50, SI) показал результат вровень с лучшими ансамблями уже «из коробки», без тюнинга: R²(log)=0.459 на IC50 (против 0.473 у RandomForest tuned) и даже меньший RMSE в исходных единицах. Это подтверждает слова лектора, что CatBoost — сильный дефолт; в продолжении работы его стоит включать в общий перебор и тюнить наравне с RF и ExtraTrees.

Методическая честность по кросс-валидации. CV для линейных моделей считалась на уже отмасштабированных данных, что слегка завышало их CV-метрики. Я перепроверил это «правильной» схемой через Pipeline (скейлер обучается заново на каждом фолде): для Ridge честный CV-R² оказался ниже (0.11 против 0.27), для RandomForest — практически без изменений (0.411 против 0.415). Итоговый вывод не изменился — ансамбли уверенно превосходят линейные модели, — а метрики на отложенном тесте и так были корректны.

- Задача $SI > 8$ требует специальных метрик при дисбалансе классов (64/36%): AP по PR-кривой более информативен, чем ROC-AUC.
- Устойчивость выбора моделей. В задачах классификации я дополнительно сверил «лучшую» модель по тесту и по кросс-валидации (без переобучения, простой пересортировкой итоговой таблицы). Для $IC50 >$ медианы обе оценки сходятся на Random Forest. Для $SI >$ медианы по CV формально вперёд выходят ансамбли, но у них велик разрыв CV-тест, тогда как у SVC $CV \approx$ тест — то есть его победа стабильна, а не случайна. Для $SI > 8$ и CV-AUC, и AP указывают на Extra Trees balanced, что совпадает с моей рекомендацией для скрининга.

4.3 Сравнение сложности задач

Целевая переменная	Тип задачи	Почему сложнее/проще	Лучший AUC/R ²	Вывод
CC50	Класс./Перп.	Физ.-хим. свойства хорошо кодируются дескрипторами	AUC=0.864 / R ² =0.491	Наилучший
IC50	Класс./Перп.	Требуется специфич. взаимодействия с вир. белком	AUC=0.784 / R ² =0.473	Хороший
SI (медиана)	Классиф.	Производная CC50/IC50 — накопл. ошибок	AUC=0.727	Умеренный
SI > 8	Классиф.	Дисбаланс 64/36%, редкий класс биол. значим	AUC=0.757 / AP=0.693	Сложный
SI (регрессия)	Регрессия	Skew=18, max=15620 — экстрем. значения	R ² =0.334	Сложный

5. Выводы и рекомендации

5.1 Выводы по результатам

По итогам проведённой работы сформулированы следующие выводы:

1. Предсказательная сила молекулярных дескрипторов умеренная для регрессии (R^2 0.33–0.49) и хорошая для классификации (AUC 0.73–0.86). Такой уровень качества соответствует литературным данным для задач виртуального скрининга на основе дескрипторов без feature engineering.
2. ExtraTrees и RandomForest — наиболее универсальные методы для данного датасета. Они стабильно занимают топ позиции благодаря нелинейности и устойчивости к масштабированию признаков. GridSearchCV каждый раз давал заметный прирост, подчёркивая важность подбора гиперпараметров.
3. $SI > 8$ — задача с наибольшей практической ценностью: именно эти соединения являются кандидатами для дальнейших испытаний. По этой задаче Extra Trees balanced (tuned) даёт $AP=0.693$, то есть значительно выше базового уровня (0.357). При $recall=70\%$ precision составляет примерно 65%, что приемлемо для первичного отбора.
4. HistGradientBoosting — перспективный метод, нативно обрабатывающий NaN. На задаче регрессии SI он показал $R^2=0.316$ без предварительной импутации, что несколько хуже RF tuned (0.334), но методологически чище.
5. SVC с RBF-ядром неожиданно стал лучшим для $SI >$ медианы (AUC=0.727). Ядровое преобразование эффективно в случаях, когда разделяющая граница «гладкая» в пространстве признаков — что характерно для производной переменной SI .

Отдельно отмечу то, что HE сработало: я возлагал надежды на GradientBoosting с тюнингом, а на CC50 он после GridSearchCV стал хуже базового. Для меня это был наглядный урок — перебор по сетке без запаса по регуляризации легко уводит в переобучение, и с тех пор я смотрю не только на лучшую метрику, но и на разрыв между train, CV и тестом.

5.2 Рекомендации по улучшению

- Отбор признаков: использовать Lasso как feature selector — оставить топ-50 дескрипторов, затем обучить ансамблевую модель. Ожидаемый прирост R^2 +0.03–0.05.
- Стекинг (StackingRegressor/Classifier): объединить ExtraTrees + RandomForest + GradientBoosting с мета-моделью (Ridge/LR). Практически всегда даёт 1–3% прироста AUC.
- Для задачи $SI > 8$: попробовать SMOTE (синтетическая аугментация миноритарного класса) для увеличения доли класса 1 в обучающей выборке.
- Feature engineering: вычислить физико-химически значимые производные признаки (logP, молекулярный вес, TPSA) — химики могут предоставить доменное знание.
- XGBoost / LightGBM: пока не тестировались (CatBoost уже проверен — см. раздел 4.2), но исторически дают лучший результат на табличных данных. LightGBM особенно эффективен при разреженных признаках (53 разреженных дескриптора в датасете).
- Калибровка вероятностей: применить CalibratedClassifierCV к ансамблевым моделям для получения корректных вероятностей, что важно для ранжирования кандидатов.

5.3 Практическая применимость

С точки зрения практического применения в разработке лекарственных средств, построенные модели могут использоваться следующим образом:

- Первичный виртуальный скрининг: модель $CC50 > \text{медианы}$ ($AUC=0.864$) позволяет отфильтровать ~75% токсичных соединений ещё на этапе *in silico*, до синтеза.
- Отбор кандидатов: модель $SI > 8$ с ET balanced ($AP=0.693$) позволяет выделить ~35% соединений для дальнейшего тестирования при recall ~65%.
- Ранжирование: регрессионные модели $IC50$ и $CC50$ ($R^2 \sim 0.47-0.49$) позволяют ранжировать соединения по ожидаемой активности и безопасности.

Оценка области применимости (Applicability Domain). По мотивам материалов МГУ я добавил в ноутбук $IC50$ простую проверку надёжности предсказаний: для каждой тестовой молекулы считается среднее расстояние до $k=5$ ближайших обучающих объектов в пространстве дескрипторов. 96.5% тестовых молекул попали внутрь области применимости (порог — 95-й перцентиль внутренних расстояний обучающей выборки), а для «далёких» точек ошибка модели оказалась примерно в 1.4 раза выше. На практике это значит, что предсказание для соединения вне области применимости нужно помечать как «низконадёжное» и проверять экспериментом в первую очередь.

Итог курсовой работы

Все 7 задач успешно решены с применением нескольких моделей и GridSearchCV. Лучшие результаты: регрессия $CC50$ $R^2=0.49$ (Extra Trees tuned), классификация $CC50 > \text{медианы}$ $AUC=0.864$ (Extra Trees tuned). Задача $SI > 8$ решена с учётом дисбаланса классов ($\text{class_weight}='balanced'$, $AP=0.693$). Код читаемый, структурированный, с подробными комментариями по каждому шагу пайплайна.